УНИВЕРСИТЕТ ИТМО

С. А. Ким, О. А. Евстафьев

Прикладной искусственный интеллект

Лабораторный практикум



Санкт-Петербург 2026

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

УНИВЕРСИТЕТ ИТМО

С. А. Ким, О. А. Евстафьев

Прикладной искусственный интеллект

ЛАБОРАТОРНЫЙ ПРАКТИКУМ

Санкт-Петербург
2026

Ким С. А., Евстафьев О. А. Прикладной искусственный интеллект: лабораторный практикум. — Санкт-Петербург: Университет ИТМО, 2026. — 48 с.

Авторы: Ким Станислав Александрович; Евстафьев Олег Александрович.

Рецензент: Шаветов Сергей Васильевич, кандидат технических наук, доцент факультета систем управления и робототехники Университета ИТМО.

Практикум по дисциплине «Прикладной искусственный интеллект» посвящён классификации, регрессии и обучению нейронных сетей. Каждая лабораторная работа объединяет теоретические сведения, примеры вычислений и план экспериментов. Электронное приложение содержит ноутбуки Python и учебные модули на основе scikit-learn, TensorFlow/Keras и PyTorch.

Для студентов бакалавриата, впервые изучающих машинное обучение и владеющих основами Python.

Об Университете ИТМО

Университет ИТМО — национальный исследовательский университет в Санкт-Петербурге. Его научные и образовательные направления включают информационные технологии и искусственный интеллект, фотонику, робототехнику, квантовые коммуникации, науки о жизни, искусство и научную коммуникацию. ИТМО участвует в программе «Приоритет-2030», развивает междисциплинарные исследования и индивидуальные образовательные траектории.

© Университет ИТМО, 2026

© Ким С. А., Евстафьев О. А., 2026

Содержание

Введение **4**

Первое знакомство с машинным обучением **5**

Подготовка среды и исходных материалов **7**

Практическая работа № 1. Классификация **9**
1.1 Задача распознавания активности 9
1.2 От сигналов к признакам 9
1.3 Разделение данных по участникам 10
1.4 Три семейства классификаторов 11
1.5 Метрики и матрица ошибок 12
1.6 Порядок выполнения 13
1.7 Отчёт и вопросы защиты 15

Практическая работа № 2. Нейронные сети **17**
2.1 Постановка задачи 17
2.2 Как используются исходные таблицы 17
2.3 Пропуски, категории и масштабирование 17
2.4 Полносвязная нейронная сеть 19
2.5 Функции активации 20
2.6 Функции потерь и метрики регрессии 20
2.7 Обучение: градиент, эпоха и мини-выборка 21
2.8 Переобучение и воспроизводимость 22
2.9 Порядок выполнения 22
2.10 Выполнение на PyTorch 26
2.11 Исследование гиперпараметров 27
2.12 Диагностика затруднений 29
2.13 Отчёт и защита работы № 2 30

Практическая работа № 3. Свёрточные нейронные сети **32**
3.1 Постановка задачи 32
3.2 Изображение как тензор 32
3.3 Свёрточный слой 33
3.4 Pooling и устройство исходной сети 33
3.5 Логиты, cross-entropy и обучение 34
3.6 Перенос обучения и заморозка 35
3.7 Подготовка изображений и разбиение 36
3.8 Обучение и исследование архитектур 37
3.9 Сравнение, визуализация и сохранение 38
3.10 Контрольные вопросы 40

Общие требования к отчёту **41**

Современные модели для таблиц: дополнительное чтение **42**

Литература **44**

Приложение А. Материалы эксперимента **46**

Приложение Б. Шаблон отчёта **48**

Введение

Машинное обучение позволяет строить правила распознавания и прогнозирования по примерам. Это одно из направлений искусственного интеллекта, которому посвящены три работы по дисциплине «Прикладной искусственный интеллект».

В каждой работе предстоит выбрать модель и объяснить её ошибки. Сначала нужно определить, что известно об объекте к моменту прогноза и как проверить ответ. От этого зависят состав признаков, способ разделения данных и метрика сравнения.

Таблица 1: Содержание лабораторных работ

№	Задача	Что исследуется	Материалы отчёта
1	Классификация активности	Сравнение алгоритмов; разделение по участникам	Отчёт по шести классам и матрица ошибок
2	Регрессия стоимости	Подготовка смешанных признаков; обучение полносвязной сети	MAE/RMSE, анализ ошибок, таблица прогнозов
3	Классификация цветов	Свёртки, перенос обучения, управление режимами модели	Сравнение трёх архитектур на одной валидации

Входная подготовка

Нужны функции и коллекции Python, чтение таблиц в pandas, простые операции с массивами NumPy, среднее и представление о производной. Вектор можно сначала понимать как список чисел, матрицу — как прямоугольную таблицу. Основы машинного обучения изложены в следующем разделе.

После вводных разделов выполняйте работы по порядку. В конце приведён необязательный обзор TabM и TabPFN-3.

Работа с примерами

Учебный модуль — файл Python с функциями, которые вызываются из ноутбука. Перед выполнением ячейки определите её вход и ожидаемый результат; после выполнения проверьте, совпало ли ожидание с наблюдением. Самостоятельная часть работы состоит в выборе настроек и объяснении результатов сравнения.

Для дальнейшего чтения о нейронных сетях можно использовать книгу «Глубокое обучение» [37], а о разработке и эксплуатации ML-систем — Machine Learning System Design [36].

Первое знакомство с машинным обучением

От примеров к правилу

Предположим, в таблице записаны площадь, число комнат и известная цена нескольких домов. Мы хотим оценить цену другого дома. В машинном обучении правило прогноза настраивают по примерам с известным ответом. Эти примеры называются **обучающими данными**, а настраиваемое правило — **моделью**.

Понятие	Пример и смысл
Объект	Один дом; в таблице ему соответствует одна строка.
Признак	Известная характеристика дома, например площадь.
Целевой ответ	То, что требуется предсказать: здесь цена.
Выборка	Набор объектов, выделенный для определённой цели.
Прогноз	Ответ модели для конкретного объекта.
Обучение	Настройка модели по признакам и известным ответам.

При **регрессии** ответ — число, например цена. При **классификации** ответ — одна из заранее заданных категорий, например «ходит» или «сидит». Категории называют классами, а правильный класс объекта — его меткой. Числовой код класса служит обозначением и не превращает задачу в регрессию.

Во всех трёх работах рассматривается **обучение с учителем**: для обучающих примеров известны правильные ответы. «Учитель» здесь означает наличие ответов в данных. Для нового объекта модель получает только те сведения, которые доступны при её применении.

Как читать обозначения

Запись x_i обозначает признаки объекта с номером i, y_i — правильный ответ, $\widehat{y}_i$ — прогноз. Например, $x_i = (80, 3)$ может описывать площадь и число комнат. Символ f_θ обозначает модель, а θ — её настраиваемые параметры:

$$\widehat{y}_i = f_\theta(x_i).$$

Модель получает признаки и вычисляет ответ. Для изображения входом служат значения пикселей; для активности человека — вычисленные характеристики сигналов.

Почему нельзя проверять только на знакомых примерах

Правило может хорошо отвечать на знакомые примеры и ошибаться на новых. Способность работать на новых объектах называют **обобщением**. Если модель слишком подстроилась под особенности обучения и хуже переносится на новые данные, говорят о **переобучении**.

Для проверки обобщения разделяют данные по ролям:

1. **Обучение (train):** настраиваем модель.
2. **Валидация (validation):** сравниваем варианты и выбираем настройки.
3. **Итоговый тест (test):** оцениваем выбранное решение, если есть отдельные данные с ответами, не использованные при выборе.

Название файла не определяет его роль. В работе № 1 `test.csv` содержит правильные ответы для итоговой проверки. В работе № 2 одноимённый файл содержит новые дома без цен: по нему можно получить прогнозы, но нельзя вычислить ошибку. Валидацию в этой работе выделяют из размеченной обучающей таблицы.

При многократном подборе настроек по одной валидации решение постепенно приспосабливается к ней. Поэтому результаты работ № 2 и № 3 характеризуют выбор в условиях данного опыта. Для независимой итоговой оценки понадобились бы дополнительные размеченные данные, которые не участвовали в выборе.

Утечка данных возникает, когда в настройку модели попадает информация, недоступная при её последующем применении. Например, цена дома осталась среди входных признаков. Утечку создаёт и вычисление статистик предобработки по всей таблице до разбиения: в этом случае подготовка обучающих признаков уже зависит от отложенных объектов [3].

Что именно меняет экспериментатор

Параметры модель находит при обучении: например, веса нейросети. **Гиперпараметры** задаёт исследователь: например, число соседей или ширину скрытого слоя. **Метрика** — число, которым оценивают качество прогноза. **Исходная модель (baseline)** — понятный вариант, с которым сравнивают изменения.

Под **протоколом** понимается заранее записанный порядок опыта: какие данные и разбиение используются, что меняется, какая метрика сравнивается. **Бюджет** ограничивает число запусков, эпох или время. **Seed** — начальное состояние генератора случайных чисел: оно помогает повторить выбор разбиения и начальных весов, но не делает оценку качества безошибочной.

> **Проверьте себя перед первой работой**
>
> Для одного дома или изображения назовите доступные признаки и искомый ответ. Какие сведения можно использовать при обучении, но нельзя передать модели при прогнозировании нового объекта?

Подготовка среды и исходных материалов

Электронное приложение к практикуму:
`https://github.com/stalkim/itmo-ml-practicum`

Структура файлов

Скачайте весь проект: ноутбуки используют функции из общей папки `code`. Данные и результаты каждой работы находятся в её собственном каталоге.

```
project/
  code/                          # common teaching modules
  labs/
    01_classification/
      lab1_activity.ipynb
      data/                      # train.csv, test.csv
    02_regression/
      lab2_housing.ipynb
      data/                      # CSV and data_description.txt
    03_cnn/
      lab3_flowers.ipynb
      data/                      # five class folders
```

Работа	Что должно быть в данных
№ 1: активность	В обеих таблицах: числовые признаки, метка `Activity`, идентификатор участника (в коде — `subject`).
№ 2: жильё	В обучающей таблице: `Id`, признаки и `SalePrice`; в таблице прогнозирования цены нет. Описание признаков находится в `data_description.txt`.
№ 3: цветы	Пять каталогов видов с изображениями. Индексы классов определяются фактическим отображением `class_to_idx`.

Файлы `train.csv` двух работ относятся к разным задачам. В репозитории размещены таблицы активности и жилья; недостающие материалы получите у преподавателя. Для третьей работы используется набор Flowers Recognition. Размеры выборок определяйте после чтения своей версии файлов.

Что такое ноутбук и как его запускать

Ноутбук Jupyter (`.ipynb`) состоит из текстовых ячеек и ячеек Python. Выполняйте их сверху вниз: переменные сохраняются в памяти между запусками. Если после изменения данных повторить только нижние ячейки, часть расчётов может опираться на старые значения. Перед сдачей перезапустите ядро (kernel) и выполните ноутбук целиком.

Запускайте код в Jupyter Notebook или JupyterLab на компьютере либо учебном сервере. GitHub позволяет просматривать и скачивать материалы. Установка и первый запуск описаны в `START_HERE.md`.

Программная среда

Для работ №1 и №2 нужны Python, NumPy, pandas, scikit-learn и Matplotlib; для второго примера также TensorFlow/Keras. Для работы №3 нужны PyTorch, совместимая с ним torchvision и Pillow. Инструкции по проверенному локальному окружению находятся в `code/README.md`.

CPU — центральный процессор компьютера. GPU ускоряет многие операции нейросетей, особенно обработку пакетов изображений. Для его использования нужны совместимые версии Python, PyTorch, torchvision и программного обеспечения ускорителя. Сначала проверьте версии установленных библиотек:

```
import sys
from importlib.metadata import version
print(sys.version)
for name in ("numpy", "pandas", "scikit-learn"):
    print(name, version(name))
```

Проверка `torch.cuda.is_available()` сообщает о доступности CUDA. Объём памяти нужно оценить отдельно: в третьей работе расчёт параметров исходной сети позволяет сделать это до длительного обучения. Небольшую проверку кода можно выполнить на CPU.

Пути в ноутбуке

Первая ячейка находит корень проекта по папкам `code` и `labs`, затем выбирает каталог работы. Короткие пути `data/train.csv` и `runs` отсчитываются от него. Поэтому ноутбук можно открыть из корня проекта или из каталога работы, сохранив структуру папок.

> **Перед запуском**
>
> Выполните ячейку подготовки и проверьте выведенный рабочий каталог. Затем прочитайте таблицу или изображение и убедитесь, что получили данные нужной работы.

Практическая работа № 1. Классификация

1.1. Задача распознавания активности

По признакам сигналов смартфона требуется определить вид активности человека. Каждый объект — временное окно измерений, представленное вектором $x_i \in \mathbb{R}^d$ из d числовых характеристик. Его истинная метка y_i известна из записи эксперимента; модель с параметрами θ выдаёт прогноз $\widehat{y}_i$:

$$\widehat{y}_i = f_\theta(x_i), \qquad y_i \in \{0, 1, 2, 3, 4, 5\}. \tag{1.1}$$

Коды классов обозначают шесть категорий активности. Сходство двух движений оценивают по признакам сигналов; расстояние между числовыми кодами меток физического смысла не имеет.

Таблица 2: Словарь меток активности

Код	Метка в файле	Смысл
0	`WALKING`	Ходьба
1	`WALKING_UPSTAIRS`	Ходьба вверх по лестнице
2	`WALKING_DOWNSTAIRS`	Ходьба вниз по лестнице
3	`SITTING`	Сидение
4	`STANDING`	Стояние
5	`LAYING`	Положение лёжа

1.2. От сигналов к признакам

В задании используется набор распознавания активности UCI HAR (Human Activity Recognition Using Smartphones). В первоисточнике 30 участников выполняли шесть действий со смартфоном на поясе; акселерометр и гироскоп регистрировали сигналы с частотой 50 Гц. Окна длиной 2,56 с содержали 128 отсчётов и перекрывались на 50%. Из каждого окна извлекался 561 признак во временной и частотной областях [1].

Акселерометр измеряет ускорение, гироскоп — угловую скорость. При подготовке сигналов фильтрация ослабляет шум, а выделение низкочастотной составляющей помогает разделить вклад гравитации и движения тела. Производные характеризуют скорость изменения сигнала; евклидова норма объединяет три оси в скалярную величину. Преобразование Фурье позволяет описать распределение энергии по частотам. Учебные файлы содержат готовые признаки этой обработки.

Таблица 3: Как читать обозначения признаков исходного задания

Обозначение	Что оно помогает описать
`tBodyAcc`, `tGravityAcc`, `tBodyGyro`	Ускорение тела, гравитационная составляющая, угловая скорость; `t` обозначает временную область.
`Jerk`, `Mag`, `XYZ`	Изменение сигнала, его модуль, отдельные оси.
Префикс `f`	Представление в частотной области после БПФ.
`mean`, `std`, `mad`, `iqr`	Характеристики положения и разброса; точное определение проверяется по описанию признаков.
`max`, `min`, `sma`, `energy`, `entropy`	Экстремумы, совокупная амплитуда, энергия и характеристика распределения сигнала.
`arCoeff`, `correlation`, `angle`	Динамическая структура, связь сигналов, геометрическое соотношение векторов.
`maxInds`, `meanFreq`, `bandsEnergy`, `skewness`, `kurtosis`	Положение частотных компонентов, энергия полос и форма распределения.

Название `energy` указывает на квадраты значений сигнала, но точная величина зависит от нормирования. Для последовательности $a_1, \ldots, a_N$ нормированная энергия может определяться как $N^{-1} \sum_i a_i^2$, где N — число отсчётов. Например, для значений $1, -1, 2, -2$ сумма квадратов равна $1 + 1 + 4 + 4 = 10$, а после деления на число отсчётов получается $10/4 = 2{,}5$. Поэтому интерпретация столбца требует его определения в описании признаков.

1.3. Разделение данных по участникам

Соседние окна исходной записи имеют 64 общих отсчёта из 128. Если такие окна одного человека попадают и в обучение, и в проверку, модель встречает близкие фрагменты записи и индивидуальные особенности уже знакомого участника. При применении к новому человеку эти условия меняются. Поэтому единица разделения в данной работе — **человек**, а единица классификации — **окно сигнала**: все окна участника относятся к одной части данных.

`GroupShuffleSplit` выбирает долю групп [2]. Участники могут иметь разное число окон, поэтому доля строк в валидации не обязана совпадать с долей участников.

Для методов, зависящих от расстояний и масштаба коэффициентов, признаки стандартизуют: $\widetilde{x}_j = (x_j - \mu_j)/s_j$. Здесь μ_j — среднее обучающего признака, а s_j — его стандартное отклонение для непостоянного столбца. Например, при $\mu_j = 10$ и $s_j = 2$ проверочное значение $x_j = 14$ преобразуется в $(14 - 10)/2 = 2$.

Обучающие и проверочные объекты используют одни и те же μ_j и s_j. Их пересчёт на проверочной части использовал бы её распределение при подготовке модели. `Pipeline` хранит преобразование вместе с классификатором: при `fit` на обучающей части он обучает scaler, при прогнозе применяет сохранённые значения [3, 4].

1.4. Три семейства классификаторов

Метод ближайших соседей

Для нового вектора находятся k ближайших обучающих объектов; класс определяется голосованием. При евклидовом расстоянии

$$\rho(x, z) = \sqrt{\sum_{j=1}^{d} (x_j - z_j)^2} \tag{1.2}$$

вклад каждой координаты входит в сумму квадратов. Например, разности 100 и 1 по двум признакам дают $\rho^2 = 10000 + 1$: первый признак почти полностью определяет расстояние. Изменение единицы его измерения может изменить состав ближайших соседей. Поэтому KNN в исходном сравнении обучается после стандартизации.

При малом k отдельный ошибочно размеченный или необычный объект сильнее влияет на голосование. Увеличение k сглаживает границу, но может включить в окрестность объекты другого класса. При равных весах каждый сосед даёт один голос; взвешивание по расстоянию усиливает влияние ближайших. Метрика задаёт само понятие близости [5].

Линейный метод опорных векторов

Для двух классов линейная граница задаётся условием $w^\mathsf{T} x + b = 0$, где w — вектор коэффициентов, а b — свободный член. При двух признаках это прямая: знак выражения определяет сторону, на которой лежит объект. В большей размерности сохраняется то же правило. Метод опорных векторов (SVM) ищет границу с широким зазором между классами, допуская штрафуемые нарушения разделения.

Параметр C задаёт вес этого штрафа относительно регуляризации, ограничивающей подгонку к обучению. При уменьшении C регуляризация усиливается, а нарушения разделения обходятся модели дешевле. Последствием могут стать как уменьшение переобучения, так и потеря полезных различий между классами; направление изменения качества устанавливается на валидации. Для шести активностей `LinearSVC` обучает линейные разделители по схеме «один класс против остальных» [6].

Случайный лес

Дерево последовательно сравнивает признаки с порогами и выдаёт класс в конечном узле. Более глубокое дерево может описать сложную границу, но также выделить малые группы, характерные только для обучения. Случайный лес (Random Forest) усредняет оценки классов, полученные деревьями. При обучении деревьев случайно выбираются объекты, а при разбиениях — доступные признаки. Различия между деревьями помогают уменьшить влияние ошибок отдельного дерева.

Глубина ограничивает сложность каждого дерева, а число деревьев влияет на устойчивость результата и вычислительные затраты. Пороговое условие сохраняет смысл при

стандартизации: например, $x_j > 14$ при $\mu_j = 10$, $s_j = 2$ соответствует $\widetilde{x}_j > 2$. Поэтому лес в исходном сравнении используется без scaler [7].

Значения k, C, глубины и числа деревьев фиксируются до обучения; коэффициенты линейной модели и пороги дерева определяются при `fit`. Смена гиперпараметров требует нового обучения. Исходным ориентиром служит `DummyClassifier`, всегда предсказывающий самый частый класс обучения. Его результат показывает, какого качества можно достичь, используя только частоты меток. Сравнение с этим ориентиром помогает оценить пользу признаков.

1.5. Метрики и матрица ошибок

Пусть C_{ij} — число объектов истинного класса i, отнесённых к классу j. Строки матрицы ошибок соответствуют истине, столбцы — прогнозу. Для класса c:

$$TP_c = C_{cc}, \qquad FP_c = \sum_{i \neq c} C_{ic}, \qquad FN_c = \sum_{j \neq c} C_{cj}, \tag{1.3}$$

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \qquad F_{1,c} = \frac{2TP_c}{2TP_c + FP_c + FN_c}. \tag{1.4}$$

Precision P_c — доля верных ответов среди всех прогнозов класса c. Recall R_c — доля найденных объектов среди всех истинных объектов этого класса. В первом знаменателе учитываются ложные положительные ответы FP_c, во втором — пропущенные объекты FN_c. F1 объединяет precision и recall и уменьшается, если хотя бы одна из них мала.

$$\mathrm{Accuracy} = \frac{\sum_c C_{cc}}{n}, \qquad \mathrm{MacroF1} = \frac{1}{6}\sum_{c=0}^{5} F_{1,c}. \tag{1.5}$$

Accuracy показывает долю верных прогнозов во всей выборке. Macro-F1 усредняет шесть значений F1 с одинаковым весом: малочисленный класс влияет на него так же, как многочисленный. Weighted-F1 использует веса, пропорциональные численности классов; эта численность называется *support*. Если модель хорошо распознаёт частые активности и пропускает редкую, accuracy и weighted-F1 могут скрыть размер проблемы. Поэтому основная метрика выбора в данной работе — macro-F1 валидации, а accuracy и показатели по классам дополняют анализ [8].

> **Расчёт метрик одного класса**
>
> Пусть для класса «сидит» модель дала 10 положительных прогнозов: восемь верны, два относятся к другим классам; ещё четыре объекта класса «сидит» пропущены. Получаем $TP = 8$, $FP = 2$, $FN = 4$. Тогда precision равна $8/10 = 0{,}8$, recall — $8/12 \approx 0{,}667$, F1 — $16/22 \approx 0{,}727$.

При нулевом знаменателе метрика не определена обычной формулой. В коде `zero_division=0` задаёт явное соглашение вывода; нулевой support или отсутствие предсказаний следует отметить. Нормирование матрицы по строкам помогает увидеть долю ошибок для каждого истинного класса, а абсолютные числа показывают объём наблюдений.

1.6. Порядок выполнения

Шаг 1. Проверьте таблицы и метки

Откройте файлы из `data`. Выведите размеры таблиц, имена столбцов, число участников, распределение классов и наличие пропусков. Найдите `Activity` и `subject`. Признаки выбирайте по именам: срез `values[:, :-2]` зависит от текущего порядка служебных столбцов. Для двух признаков приведите определение из описания данных и объясните, какое свойство сигнала они характеризуют.

```
from pathlib import Path
import pandas as pd
train = pd.read_csv(Path("data/train.csv"))
test = pd.read_csv(Path("data/test.csv"))
print(train.shape, test.shape)
print(train["Activity"].value_counts())
print(train["subject"].nunique(), test["subject"].nunique())
```

Шаг 2. Выделите валидацию

Отведите внешний `test.csv` для единственной итоговой оценки выбранной модели. Из участников `train.csv` выделите примерно 20% в валидацию с фиксированным seed 40. Выбор seed по наилучшей метрике добавил бы подбор самого разбиения.

Учебный модуль проверяет метки и признаки, исключает целевой столбец и идентификатор участника, затем выполняет групповое разделение. Если идентификатор называется иначе, укажите его через `group_column`. При его отсутствии уточните состав выгрузки и протокол: фиктивные номера, полученные из номеров строк, не позволяют проверить перенос на новых людей.

```
from lab1_utils import load_har, candidate_models, fit_validation
from lab1_utils import CLASSES, final_test, save_har_result
data = load_har("data", group_column="subject", seed=40)
print(data["Xtr"].shape, data["Xva"].shape)
print(data["training_subjects"], data["validation_subjects"])
```

Проверка разбиения и входов

Проверьте, что каждая часть содержит все шесть классов, участники обучения и валидации не пересекаются, а участники внешнего теста отсутствуют в обеих частях. Во входах нет `Activity` и идентификатора участника. Столбцы теста приведены к порядку обучающих признаков по именам. Scaler обучается только на обучающей части; валидация и тест используют сохранённое преобразование.

Шаг 3. Сравните конфигурации

До запуска сформулируйте ожидаемое влияние k, C и глубины деревьев. Выполните исходный план из таблицы, затем переходите к собственным опытам. Допускается иной набор нескольких алгоритмов с сопоставимым и заранее определённым объёмом исследования. Используйте библиотечные реализации; самостоятельная реализация алгоритмов не требуется.

Таблица 4: Исходный план сравнения классификаторов

Обозначения	Модель	Меняемый параметр
D0	Dummy	Самый частый класс; ориентир без использования признаков
K3, K7, K15	KNN	$k \in \{3, 7, 15\}$; одинаковое масштабирование
S0.1, S1, S10	LinearSVC	$C \in \{0{,}1, 1, 10\}$; остальные настройки фиксированы
R8, RNone	Random forest	Глубина 8 или без ограничения; 200 деревьев

```
models = candidate_models(seed=40)
rows = []
for name, estimator in models.items():
    result = fit_validation(data, estimator)
    rows.append({"model": name, **result["metrics"],
                 "seconds_fit": result["seconds_fit"]})
comparison = pd.DataFrame(rows)
print(comparison.sort_values("macro_f1", ascending=False))
```

Для всех конфигураций цикл использует одно разбиение на обучение и валидацию. Выберите строку таблицы и объясните, какие прогнозы входят в её macro-F1. Сохраняйте предупреждения о сходимости. Если модель не сошлась, выясните причину и отдельно зафиксируйте изменение бюджета или настройки; общее отключение `warnings` скрыло бы различие условий сравнения.

Шаг 4. Визуализируйте и зафиксируйте выбор

Постройте столбчатую диаграмму macro-F1 всех конфигураций и отдельную диаграмму времени обучения: эти величины имеют разные единицы и смысл. По валидационным показателям назовите хуже всего распознаваемые классы и возможные причины ошибок. Выберите конфигурацию по macro-F1 валидации. При близких результатах учитывайте сложность

и время; вывод об устойчивости небольшого различия требует повторной проверки в заранее заданном протоколе.

```
import matplotlib.pyplot as plt
comparison.plot.bar(x="model", y="macro_f1", legend=False)
plt.ylabel("Validation macro-F1")
plt.tight_layout()
```

Шаг 5. Выполните итоговый тест

Зафиксируйте выбранную конфигурацию, затем переобучите её на всём `train.csv`. Scaler внутри `Pipeline` также обучается заново: после выбора модели бывшая валидация становится частью обучающих данных. Получите один итоговый прогноз `yhat` для `test.csv` и сохраните результат. Код ниже выбирает максимум macro-F1 валидации; при равенстве метрик порядок определяется именем модели.

```
selected = comparison.sort_values(
    ["macro_f1", "model"], ascending=[False, True]
).iloc[0]["model"]
final = final_test(data, models[selected])
yhat = final["prediction"]
print(pd.DataFrame(final["report"]).T)
save_har_result(data, comparison, selected, final, "runs/lab1_01")
```

Разберите полученное тестовое качество, даже если оно хуже ожидаемого. Возвращение к подбору настроек после просмотра теста использует тестовые ответы для выбора модели и лишает оценку независимости.

Шаг 6. Разберите ошибки

Постройте матрицу ошибок для итоговых прогнозов с одинаковым порядком шести меток. Выведите абсолютные числа и нормирование по строкам. При чтении элемента C_{ij} назовите истинное действие i и ошибочный прогноз j. Разберите хотя бы две заметные пары перепутанных действий; отдельно укажите наблюдаемую ошибку и предполагаемую причину.

```
from sklearn.metrics import ConfusionMatrixDisplay
ConfusionMatrixDisplay.from_predictions(
    data["ytest"], yhat, labels=range(6),
    display_labels=CLASSES, normalize="true", xticks_rotation=90
)
plt.tight_layout()
```

1.7. Отчёт и вопросы защиты

В отчёте по работе № 1 должны быть паспорт файлов и объяснение двух признаков, состав разбиения по участникам, мотивация выбора алгоритмов, таблица всех конфигураций, диаграммы macro-F1 и времени обучения, итоговый `classification_report` и обе формы

матрицы ошибок. Объясните precision, recall и F1 на примере одного класса. Сохраните точные параметры модели, версии библиотек, seed и идентификаторы групп. В выводе объясните влияние гиперпараметров, укажите выбранный вариант, хуже всего распознаваемые классы и следующий проверяемый вопрос. Вывод о новых людях ограничьте проверенными группами и условиями записи.

1. Что является объектом, признаком, целевой меткой и группой в этой работе?
2. Почему код активности нельзя трактовать как непрерывную величину?
3. Какую информацию дают акселерометр и гироскоп? Зачем нужны признаки частотной области?
4. Почему разбиение строк и разбиение участников проверяют разные условия применения?
5. Чем precision отличается от recall? Постройте собственный пример с FP и FN.
6. Как рассчитывается F1? Чем macro-F1 отличается от weighted-F1 и accuracy?
7. Чем гиперпараметр отличается от параметра обученной модели?
8. Как изменение k, C и глубины деревьев повлияло на ваши результаты?
9. Почему scaler обучается только на обучающей части? Для каких моделей он особенно существенен?
10. Что означает нулевой support? Почему следует сохранять порядок меток в отчёте?
11. Почему нельзя выбрать победителя по внешнему тесту и затем назвать этот тест независимым?

Практическая работа № 2. Нейронные сети

2.1. Постановка задачи

По характеристикам дома требуется предсказать `SalePrice`. Для дома i подготовленные признаки образуют вектор x_i, известная цена обозначается y_i, а сеть f_θ с параметрами θ вычисляет прогноз:

$$\widehat{y}_i = f_\theta(x_i), \qquad y_i \in \mathbb{R}_{>0}. \tag{2.1}$$

В этой работе мы подготовим табличные данные, обучим полносвязную сеть и исследуем, как её настройки влияют на ошибку. Выбранная конфигурация даст прогноз для домов из `test.csv`.

2.2. Как используются исходные таблицы

В `train.csv` цены известны. Его строки делятся на обучающую часть (80%) и валидационную (20%): по первой настраиваются преобразования и веса сети, по второй сравниваются конфигурации. Файл `test.csv` содержит дома без известных цен, поэтому служит для получения прогнозов и не позволяет измерить их ошибку.

Подготовка данных тоже использует информацию из примеров. Например, медиана зависит от набора строк, по которому её вычислили. Если найти её по всему `train.csv` до разделения, в подготовку обучения попадут сведения о валидации. Если же независимо кодировать категории в разных таблицах, один числовой код может получить разные значения. Для корректного сравнения нужна одна система преобразований.

> **Предобработка и применение модели**
>
> Медианы, средние, масштабы и словарь категорий определяются по обучающей части. Валидация и новые дома преобразуются с уже найденными параметрами: `fit_transform` на обучении, `transform` на остальных данных [3].

Случайное разделение здесь опирается на учебное предположение о независимых однородных наблюдениях. Временной прогноз, повторные продажи одного объекта или группы зависимых домов потребовали бы другого разбиения. Это предположение необходимо указать в отчёте.

2.3. Пропуски, категории и масштабирование

Числовые пропуски в исходной конфигурации заменяются медианой обучающей части. По сравнению со средним медиана меньше реагирует на отдельные очень большие значения, поэтому такие наблюдения слабее влияют на заполнение пропусков [9].

Категориальные пропуски получают значение `__missing__`. При этом описание данных помогает различить неизвестное значение и отсутствие объекта, например гаража. Эти

случаи могут иметь разный смысл для цены. В исходной конфигурации по условию задания удаляются пять столбцов: `Alley`, `FireplaceQu`, `PoolQC`, `Fence`, `MiscFeature`. Фиксированный список обеспечивает одинаковые условия опытов; другие способы работы с этими признаками можно исследовать отдельно.

Категории без естественного порядка кодируются методом *one-hot*: каждой известной категории соответствует отдельный бинарный столбец. Например, число, обозначающее вид покрытия, не должно само по себе задавать расстояние между видами.

> **Кодирование трёх категорий**
>
> Для категорий A, B, C возможны коды $A \mapsto (1,0,0)$, $B \mapsto (0,1,0)$, $C \mapsto (0,0,1)$. Замена их числами $1, 2, 3$ навязывает порядок и расстояния, которых в описании признака может не быть.

Обученный кодировщик задаёт состав и порядок столбцов. Для неизвестных категорий используется `handle_unknown="ignore"`: они получают нулевой блок индикаторов [10]. Это позволяет вычислить прогноз, но модель не приобретает знаний о новой категории. Её появление следует отметить при анализе данных.

Числовые признаки приводятся к сопоставимому масштабу:

$$\widetilde{x}_{ij} = \frac{x_{ij} - \mu_j}{s_j}, \tag{2.2}$$

где μ_j, s_j вычислены по обучающей части после заполнения пропусков. Для постоянного признака реализация использует масштаб 1, чтобы избежать деления на ноль. Стандартизация меняет масштаб, но сохраняет зависимости между признаками и форму их распределений; она не делает распределение нормальным [4].

Целевая цена в примере также стандартизуется:

$$z_i = \frac{y_i - \mu_y}{s_y}, \qquad \widehat{y}_i = \mu_y + s_y \widehat{z}_i. \tag{2.3}$$

Сеть обучается предсказывать z_i, то есть работает с числами умеренного масштаба. Для оценки ошибки в денежных единицах и сохранения прогнозов применяется обратное преобразование с теми же μ_y, s_y, которые найдены на обучении. Средняя цена валидации в это преобразование не входит.

В статье Uber Engineering от 5 сентября 2017 года описано, как в Michelangelo правила преобразования признаков входят в конфигурацию модели и одинаково применяются при обучении и прогнозировании [34]. В лабораторной тот же принцип согласованности требует сохранять обученную предобработку вместе с моделью: новые дома должны проходить через прежние преобразования.

2.4. Полносвязная нейронная сеть

Полносвязную сеть с одним или несколькими скрытыми слоями часто называют многослойным перцептроном (MLP, *multilayer perceptron*). Нейрон полносвязного слоя вычисляет взвешенную сумму входов, добавляет смещение и применяет функцию активации:

$$a_j = \sum_{k=1}^{d} w_{jk} x_k + b_j, \qquad h_j = \varphi(a_j). \tag{2.4}$$

В матричной записи для слоя ℓ:

$$h^{(\ell)} = \varphi\big(W^{(\ell)} h^{(\ell-1)} + b^{(\ell)}\big), \qquad h^{(0)} = \widetilde{x}. \tag{2.5}$$

Выходы одного слоя становятся входами следующего. Для сети с одним скрытым слоем и линейным выходом получаем

$$\widehat{z} = v^{\mathsf{T}} \varphi(W\widetilde{x} + b) + c. \tag{2.6}$$

В Keras такую последовательность задаёт `keras.Sequential`, а полносвязный слой представлен `Dense` [11, 12].

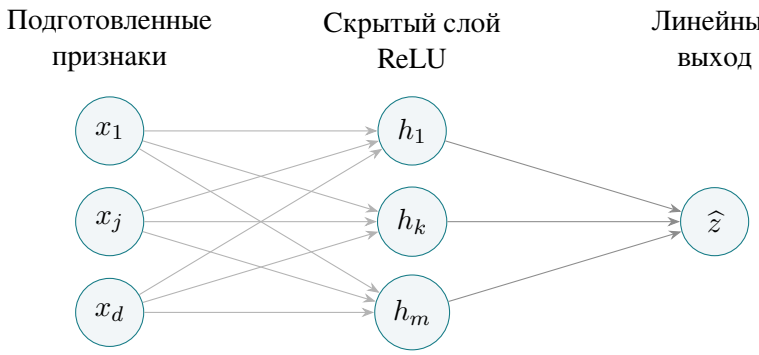


Рис. 1: Схема полносвязной сети. Число входов определяется после предобработки; на схеме показана часть связей.

Входная размерность d определяется числом подготовленных признаков. Изменение ширины **первого скрытого полносвязного слоя** меняет число нейронов, обрабатывающих этот вектор, и сохраняет число его компонент. На выходе нужен один нейрон, поскольку для каждого дома предсказывается одна цена.

У слоя с d входами и m нейронами имеется $dm + m$ обучаемых параметров: dm весов и m смещений. Для схемы $d \to m \to 1$ их всего

$$P = (d + 1)m + (m + 1). \tag{2.7}$$

Например, при $d = 10$, $m = 8$ получаем $P = 97$: первый слой содержит 88 параметров, выходной — 9. В файлах курса размерность определяется предобработкой; для неё расчёт можно проверить командой `model.count_params()`.

2.5. Функции активации

Без нелинейной активации последовательность линейных слоёв сводится к одному аффинному преобразованию — взвешенной сумме входов со смещением. Нелинейность позволяет сети описывать более сложные зависимости.

Активация	Формула	Особенность
ReLU	$\max(0, a)$	Простая исходная активация скрытых слоёв; на отрицательной полуоси производная равна нулю.
Sigmoid	$1/(1 + e^{-a})$	Выход в $(0, 1)$; в областях насыщения производная мала.
Tanh	$\tanh(a)$	Выход в $(-1, 1)$; также имеет области насыщения.
Линейная	a	Не ограничивает диапазон прогноза.

В исходной сети используется ReLU в скрытом слое и линейная функция на выходе [13]. Sigmoid без согласованного преобразования цели ограничила бы прогноз интервалом $(0, 1)$. Стандартизованная цена может быть отрицательной: такое значение соответствует цене ниже μ_y. Допустимость прогнозируемой цены проверяется после обратного преобразования.

2.6. Функции потерь и метрики регрессии

Для n оцениваемых объектов обозначим ошибку $e_i = y_i - \widehat{y}_i$. Тогда

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n} e_i^2, \tag{2.8}$$

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |e_i|, \tag{2.9}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} e_i^2}. \tag{2.10}$$

MAE и RMSE измеряются в единицах цены, MSE — в квадрате этих единиц. Квадрат ошибки усиливает вклад крупных промахов, тогда как в MAE вклад растёт пропорционально абсолютной величине ошибки [14].

> **Расчёт ошибок**
>
> Пусть цены равны $(100, 150, 200)$, а прогнозы — $(110, 140, 230)$ в условных денежных единицах. Абсолютные ошибки составляют 10, 10 и 30, а их квадраты — 100, 100 и 900. Поэтому $\mathrm{MAE} = 50/3 \approx 16{,}67$, $\mathrm{MSE} = 1100/3 \approx 366{,}67$, $\mathrm{RMSE} \approx 19{,}15$.

Дополнительно можно вычислить коэффициент детерминации

$$R^2 = 1 - \frac{\sum_i (y_i - \widehat{y}_i)^2}{\sum_i (y_i - \overline{y})^2}. \tag{2.11}$$

Здесь $\overline{y}$ — среднее по *оцениваемой* части. Оно входит в определение метрики и не используется для предобработки. Значение R^2 может быть отрицательным и не выражает процент точных ответов. При постоянной цели знаменатель равен нулю, поэтому формула не определена [15].

Обучение минимизирует выбранную функцию потерь; конфигурации сравниваются по общим метрикам. Поэтому при смене MSE на MAE значения `loss` нельзя сопоставлять напрямую. Во всех опытах главным критерием служит MAE валидации в исходных единицах цены, а RMSE помогает оценить влияние крупных ошибок.

Для преобразования (2.3) справедливо $\mathrm{MAE}_y = s_y \,\mathrm{MAE}_z$ и $\mathrm{MSE}_y = s_y^2 \,\mathrm{MSE}_z$. Из-за этого MAE в журнале обучения на стандартизованной цели отличается по численному значению от MAE в денежных единицах.

2.7. Обучение: градиент, эпоха и мини-выборка

Чтобы уменьшить потерю, алгоритм изменяет веса и смещения сети. Градиент показывает направление её наиболее быстрого роста при малом изменении параметров. В обычном градиентном методе обновление направлено в противоположную сторону, а его величину регулирует скорость обучения. Для мини-выборки B_t шаг имеет вид

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta \frac{1}{|B_t|} \sum_{i \in B_t} \ell(y_i, f_\theta(x_i)), \tag{2.12}$$

где $\eta > 0$ — скорость обучения. Для вычисления производных используется цепное правило. Передачу производных от выхода сети к предшествующим слоям называют обратным распространением ошибки.

Один шаг обучения

Пусть $\widehat{y} = wx + b$, $x = 2$, правильный ответ $y = 6$, начальные $w = 1$, $b = 0$. Прогноз равен 2, а квадратичная потеря $(\widehat{y} - y)^2 = 16$. Производные:

$$\frac{\partial L}{\partial w} = 2(\widehat{y} - y)x = -16, \qquad \frac{\partial L}{\partial b} = 2(\widehat{y} - y) = -8.$$

При шаге $0{,}01$ получаем $w = 1{,}16$, $b = 0{,}08$. Новый прогноз равен $2{,}4$, потеря — $12{,}96$: обновление уменьшило ошибку этого объекта. В многослойной сети тот же принцип требует вычислить производные через все слои.

Итерация здесь соответствует одному обновлению весов по мини-выборке, **эпоха** — проходу по всей обучающей части. Если в ней N строк и последний неполный пакет

сохраняется, число обновлений за эпоху равно $\lceil N/b \rceil$, где b — `batch_size`. При $N = 1000$, $b = 32$ это 32 обновления, а за 10 эпох — 320 [16].

Меньший пакет даёт больше обновлений за эпоху и обычно более шумную оценку градиента. Поэтому равное число эпох при разных пакетах задаёт разное число обновлений. Скорость обучения тоже влияет на ход процесса: слишком большой шаг может вызвать колебания или расходимость, слишком малый — замедлить улучшение.

В работе сравниваются SGD и Adam. SGD использует градиент текущего пакета; Adam накапливает оценки первого и второго моментов градиента и адаптирует масштаб обновлений [17, 18]. Одинаковая численная скорость обучения даёт этим алгоритмам разные траектории и может подходить им в разной степени.

2.8. Переобучение и воспроизводимость

Если ошибка обучения продолжает уменьшаться, а ошибка валидации перестаёт улучшаться или растёт, возникает подозрение на переобучение. Кривые показывают расхождение поведения на двух частях данных, но для выяснения причины нужно также проверить подготовку данных, размер выборки, архитектуру и скорость обучения.

Регуляризация ограничивает подгонку к особенностям обучения. Штраф L2 добавляет к потере величину, растущую с квадратами весов. Dropout при обучении случайно отключает часть выходов скрытого слоя; при прогнозировании отключение прекращается. Влияние обоих приёмов проверяется на валидации; исходная конфигурация их не содержит.

Ранний останов прекращает обучение после заданного числа эпох без улучшения валидационной метрики. В Keras его реализует `EarlyStopping`; возврат лучших сохранённых весов задаётся параметром `restore_best_weights=True` [19]. В основных опытах ранний останов выключен: сравниваются результаты после заданного числа проходов. Его влияние исследуется отдельно.

В протоколе используется одно разбиение и исходный seed 40. Команда `keras.utils.set_random_seed` задаёт начальные состояния генераторов; включение детерминированных операций дополнительно уменьшает случайность вычислений [20]. Для повторения опыта нужны также версии библиотек и сведения об устройстве. Один seed не оценивает устойчивость результата и не гарантирует побитового совпадения на разных программных и аппаратных платформах [21].

2.9. Порядок выполнения

Сначала выполните B0: проследите путь одного дома от строки таблицы через подготовку признаков до прогноза и объясните полученную MAE в денежных единицах. После этого переходите к сравнению конфигураций.

Шаг 1. Изучите исходные таблицы

Откройте таблицы и описание данных. Проверьте число строк и столбцов, уникальность `Id` внутри каждого файла и наличие `SalePrice` только в `train.csv`. Выберите два числовых и два категориальных признака и объясните их смысл.

```
from pathlib import Path
import pandas as pd

DATA_DIR = Path("data")
train_data = pd.read_csv(DATA_DIR / "train.csv")
test_data = pd.read_csv(DATA_DIR / "test.csv")
print(train_data.shape, test_data.shape)
print(train_data.head())
print(test_data.head())
print(train_data.isna().sum().sort_values(ascending=False).head(10))
```

`Id` связывает прогноз с домом и исключается из признаков. Если в размеченной строке отсутствует целевая цена, её нельзя заменять медианой: для этой строки нет достоверного ответа, по которому можно обучать модель.

Шаг 2. Разделите и подготовьте данные

Отделите `SalePrice` и `Id`, сохраните удаление пяти заданных столбцов и разделите сырые строки в отношении 80/20 с `random_state=40`. Затем обучите предобработку на обучающей части. Эти действия реализованы в `lab2_utils.py`; в функции `prepare_frames` найдите, где вычисляются статистики.

```
import sys
sys.path.insert(0, "code")
from lab2_utils import load_course_data, constant_baselines

data = load_course_data(DATA_DIR, seed=40)
print(data["Atr"].shape, data["Ava"].shape, data["Atest"].shape)
print(data["removed_columns"])
print(data["feature_names"][:10])
```

В числовом конвейере пропуски заменяются медианой, затем выполняется стандартизация. Категориальный конвейер заполняет пропуски отдельной категорией и выполняет one-hot-кодирование. `ColumnTransformer` направляет соответствующие столбцы в каждый конвейер [22]. Для признаков с целочисленными кодами сверьтесь со словарём: формат хранения не определяет содержательный смысл признака.

Проверьте результат: три матрицы должны иметь одинаковое число столбцов и не содержать NaN или бесконечностей. Пересечение `train_ids` и `validation_ids` должно быть пустым, а объекты валидации должны проходить только через `transform`. Число входов сети равно `data["Atr"].shape[1]`.

Шаг 3. Рассчитайте константные прогнозы

Вычислите среднюю и медианную цену обучающей части. Используйте каждое значение как прогноз для всех валидационных домов и рассчитайте MAE и RMSE.

```
baseline_table = pd.DataFrame(constant_baselines(data)).T
print(baseline_table)
```

Константный прогноз позволяет проверить, насколько полезна информация из признаков. Если нейросеть не улучшила результат, это необходимо показать и разобрать возможные причины.

Шаг 4. Постройте сеть B0

Входная размерность определяется подготовленной матрицей. Скрытый слой содержит 64 нейрона с ReLU, линейный выход предсказывает одно стандартизованное значение цены. Компиляция задаёт Adam со скоростью обучения 10^{-3}, потерю MSE и наблюдаемую MAE.

```
from tensorflow import keras

keras.utils.set_random_seed(40)
d = data["Atr"].shape[1]
model = keras.Sequential([
    keras.Input(shape=(d,)),
    keras.layers.Dense(64, activation="relu"),
    keras.layers.Dense(1, activation="linear"),
])
model.compile(
    optimizer=keras.optimizers.Adam(learning_rate=1e-3),
    loss="mse",
    metrics=[keras.metrics.MeanAbsoluteError(name="mae")],
)
model.summary()
```

Рассчитайте число параметров этой сети вручную и сопоставьте его со сводкой модели. При изменении ширины или глубины повторите расчёт, чтобы связать устройство сети с её сложностью.

Шаг 5. Обучите сеть и сохраните историю

Передайте `Atr` и стандартизованную цель `ztr`. В аргументе `validation_data` явно укажите `Ava` и `zva`. Таблица `test_data` не содержит ответов и для этого аргумента не подходит.

```
history = model.fit(
    data["Atr"], data["ztr"],
    validation_data=(data["Ava"], data["zva"]),
    epochs=100, batch_size=32, shuffle=True, verbose=0,
)
```

Функция `run_experiment` выполняет ту же последовательность целиком: создаёт новую модель, обучает её, возвращает прогноз к исходной шкале и рассчитывает метрики. Выберите собственную последовательность шагов или эту функцию для одного опыта, поскольку её вызов после `model.fit` запускает обучение ещё одной сети.

```
from lab2_utils import run_experiment, plot_diagnostics

result = run_experiment(
    data, hidden=(64,), epochs=100, batch_size=32,
    optimizer="adam", learning_rate=1e-3,
    loss="mse", seed=40, early_stop=False,
)
print(result["metrics"])
fig = plot_diagnostics(data, result)
```

Шаг 6. Оцените качество и разберите ошибки

Для всех конфигураций используйте одни и те же валидационные дома. MAE и RMSE итогового сравнения рассчитывайте после обратного преобразования цели. Постройте три графика:

1. MAE обучения и валидации по эпохам.
2. Предсказанная цена против фактической; прямая $\widehat{y} = y$ показывает положение идеальных прогнозов.
3. Остаток $e = y - \widehat{y}$ против предсказанной цены с горизонтальной линией $e = 0$.

В подписях укажите модель, часть данных и единицы измерения. По двум последним графикам определите, где возникают крупные промахи, систематическое завышение или занижение цены и изменение разброса ошибок.

Рассмотрите исходные характеристики пяти домов с наибольшей абсолютной ошибкой. Эти объекты остаются в валидации, даже если ухудшают метрику. Предполагаемую ошибку данных опишите как проверяемую гипотезу и укажите, какие сведения нужны для проверки.

Шаг 7. Получите и сохраните прогнозы

После выбора конфигурации вычислите прогноз для всех строк `test.csv`. В базовом варианте сохраняется модель, обученная на 80% размеченных строк; её оценка получена на оставшихся 20%.

```python
import numpy as np
from lab2_utils import save_experiment

preds = np.asarray(result["predictions"]).reshape(-1)
output = pd.DataFrame({
    "Id": data["prediction_ids"],
    "SalePrice": preds,
})
assert len(output) == len(test_data)
assert output["Id"].tolist() == test_data["Id"].tolist()
assert np.isfinite(output["SalePrice"]).all()
print("Negative prices:", int((output["SalePrice"] < 0).sum()))
save_experiment(data, result, "runs/baseline_01")
```

Сопоставление `Id` проверяет связь прогнозов с исходными домами. Отрицательная цена требует проверки обучения и обратного преобразования. Если вводится постобработка, обоснуйте её по валидации и примените одинаково к прогнозам для валидации и `test.csv`. Файл `predictions_raw.csv` должен сохранять исходные значения.

После фиксации настроек допускается отдельное финальное переобучение на всём `train.csv`. В этом случае заново обучаются предобработка и сеть. Прежняя валидационная ошибка характеризует прежнюю модель; строки, вошедшие в финальное обучение, уже не дают независимой оценки новой модели.

2.10. Выполнение на PyTorch

При выборе PyTorch сохраните разбиение, предобработку, архитектуру, метрики и исследуемые факторы. Обычный интерфейс этой библиотеки требует явного цикла обучения. Вместо `model.compile()` и `model.fit()` выполняется следующая последовательность [23]:

```python
model.train()
for xb, yb in train_loader:
    optimizer.zero_grad()
    prediction = model(xb)
    loss = criterion(prediction, yb)
    loss.backward()
    optimizer.step()

model.eval()
with torch.no_grad():
    val_prediction = model(X_val_tensor)
```

В режиме обучения обнуляются предыдущие градиенты, вычисляется прогноз и потеря, затем производные и обновление весов. Для валидации `model.eval()` переключает поведение слоёв, а `torch.no_grad()` отключает запись операций для вычисления градиентов. Это разные действия, поэтому выполняются оба.

Загрузчик, модель, оптимизатор и тензоры в этом фрагменте нужно создать самостоятельно. Прогноз и цель должны иметь одинаковую форму $(b, 1)$: сочетание $(b, 1)$ и $(b,)$

допускает нежелательное расширение размерностей при вычислении потерь. Используйте `MSELoss` и `L1Loss` для соответствующих опытов. При одном seed TensorFlow и PyTorch могут получить разные веса и метрики; результаты сравниваются с учётом соблюдения общего протокола.

2.11. Исследование гиперпараметров

Сформулируйте ожидаемое влияние каждого изменения до запуска. В каждом сравнении изменяется один фактор относительно B0. Создавайте новую сеть и новый оптимизатор: при продолжении обучения в результат вмешивается предыстория весов.

> **Условия основных опытов**
>
> Разделение 80/20; seed 40; одинаковая подготовка признаков и цели; ReLU в скрытых слоях; линейный выход; скорость обучения 10^{-3}. Основные опыты проводятся без раннего останова.

План включает десять конфигураций. Преподаватель может скорректировать бюджет до начала занятия; принятые условия фиксируются до запусков.

Таблица 5: План сравнения. В столбце «слои» указаны ширины скрытых слоёв.

Опыт	Слои	Эпохи	Пакет	Оптимизатор	Потеря
B0	64	100	32	Adam	MSE
W1	32	100	32	Adam	MSE
W2	128	100	32	Adam	MSE
D1	64, 32	100	32	Adam	MSE
E1	64	30	32	Adam	MSE
E2	64	200	32	Adam	MSE
P1	64	100	16	Adam	MSE
P2	64	100	64	Adam	MSE
O1	64	100	32	SGD	MSE
L1	64	100	32	Adam	MAE

Для каждой группы сравнений ответьте на свой вопрос:

1. **Ширина: B0, W1, W2.** Как изменение числа параметров связано с ошибкой и разрывом между обучением и валидацией?
2. **Глубина: B0, D1.** Что добавляет второй скрытый слой и оправдывает ли изменение ошибки усложнение сети?
3. **Эпохи: E1, B0, E2.** На каком участке кривых сохраняется улучшение? Что происходит к концу каждого запуска?
4. **Пакет: P1, B0, P2.** Рассчитайте число обновлений весов и свяжите его с результатом. Равное число эпох при разных пакетах даёт разное число обновлений.

5. **Оптимизатор: B0, O1.** Как изменились кривые и итоговая ошибка при фиксированном шаге? Вывод относится к этим настройкам; для сравнения Adam и SGD с индивидуально подобранными скоростями обучения нужны отдельные опыты.
6. **Потеря: B0, L1.** Сравните MAE и RMSE в исходных единицах цены. Какие крупные ошибки изменились при переходе к MAE?

Журнал результатов

Для каждого запуска сохраните идентификатор, архитектуру, число параметров, заданные и выполненные эпохи, размер пакета, оптимизатор, скорость обучения, функцию потерь, seed, время обучения, MAE, RMSE и при необходимости R^2. Конфигурация и рассчитанные метрики собираются в одну строку:

```
row = {
    "experiment": "B0",
    **result["config"],
    **result["metrics"],
}
pd.DataFrame([row]).to_csv("experiment_B0.csv", index=False)
```

Выбор конфигурации

Выберите конфигурацию по MAE валидации. Затем рассмотрите RMSE, сложность сети и графики ошибок: они помогают объяснить выбор. Малую разницу по одному запуску следует описать как наблюдение на данном разбиении и указать проверку, нужную для оценки устойчивости.

В `test.csv` нет правильных цен, поэтому его прогнозы не дают основания подбирать гиперпараметры. В работе не задан универсальный порог MAE или обязательная победа над другими алгоритмами; оценка зависит от корректности опыта и обоснованности выводов.

Дополнительные исследования

По согласованию с преподавателем выполните одно расширение:

- включите ранний останов по MAE валидации и сравните с B0; укажите фактическую длину обучения и правило возврата весов;
- исследуйте влияние отдельной скорости обучения у SGD;
- сравните фиксированное удаление пяти признаков с сохранением их содержательно интерпретированных категорий;
- повторите две выбранные конфигурации с несколькими заранее заданными seed и покажите разброс на том же фиксированном разбиении.

В журнале дополнительных опытов явно укажите изменённые условия, чтобы их результат можно было сопоставить с исходным планом.

2.12. Диагностика затруднений

Наблюдение	Возможная причина	Проверка
Разное число входных признаков	Кодировщики обучены независимо для разных таблиц	Сопоставить имена и порядок столбцов; использовать один обученный кодировщик.
Подозрительно малая ошибка	Цена попала в признаки или статистики получены до разделения	Проверить входы и строки, по которым выполнен `fit`.
Потеря равна NaN	Остались NaN или бесконечности; обучение расходится	Проверить массивы и цель, затем масштаб и скорость обучения.
Прогнозы около нуля	Сохранена стандартизованная цель	Проверить обратное преобразование с `target_scaler`, обученным на y_{train}.
Крупные ошибки у дорогих домов	Редкие сочетания признаков или ошибка в части диапазона	Рассмотреть остатки и характеристики этих домов; сохранить их в оценке.
Отрицательные цены после обратного преобразования	Ошибка шкалы или поведение модели	Проверить преобразование; оценить изменение модели или постобработку на валидации.
Результат меняется при повторе	Изменились разбиение, инициализация или начальные веса	Сопоставить seed, версии, идентификаторы строк и создание новой модели.
Ошибка формы тензоров в PyTorch	Цель имеет форму $(b,)$, выход — $(b, 1)$	Привести обе формы к $(b, 1)$.

2.13. Отчёт и защита работы № 2

Оформите отчёт по разделу «Общие требования к отчёту» и шаблону приложения 3.10. Для лабораторной № 2 представьте следующие материалы:

1. Описание выбранных признаков и предобработки: удалённые столбцы, заполнение пропусков, кодирование категорий и масштабирование. Укажите разбиение 80/20 с seed 40 и покажите, что статистики вычислены только по обучающей части.
2. Архитектуру B0, размерности слоёв и расчёт числа параметров.
3. Таблицу MAE и RMSE константных прогнозов по средней и медиане обучающих цен и всех десяти конфигураций основного плана. Объясните влияние исследованных факторов, выбор по MAE валидации и ограничения вывода.
4. Три графика: MAE обучения и валидации по эпохам, предсказанные цены против фактических, остатки против предсказанных цен. Разберите характеристики пяти домов с наибольшей абсолютной ошибкой.
5. Пример итоговой таблицы с полями `Id` и `SalePrice`, а также полный CSV-файл прогнозов. Состав и порядок `Id` должны совпадать с `test.csv`; исходные прогнозы сохраняются в `predictions_raw.csv`.

К ноутбуку и коду изменений приложите журнал запусков и файлы `history.csv`, `validation_predictions.csv`, `model.keras`, `preprocessing.joblib` и `manifest.json`. Комплект должен фиксировать исходные данные, идентификаторы разбиения, конфигурации, seed и версии библиотек; сведения об устройстве укажите в отчёте. Если вводилась постобработка цен или финальное переобучение на всём `train.csv`, опишите их отдельно и укажите, к какой модели относится валидационная оценка.

Вопросы к защите

1. Почему для `SalePrice` решается задача регрессии? Какие сведения о доме доступны модели при прогнозировании?
2. Как используются обучающие и валидационные строки `train.csv` и дома из `test.csv`? Где выбирались гиперпараметры вашей модели?
3. Как независимое обучение кодировщиков на двух таблицах нарушает соответствие признаков? Приведите пример с категориями.
4. Что изменило масштабирование признаков и целевой цены? Как вы вернули прогноз к исходным единицам?
5. Что вычисляет полносвязный слой и сколько параметров в каждом слое вашей сети?
6. Почему изменение ширины скрытого слоя сохраняет входную размерность при той же предобработке?
7. Как выбор ReLU, sigmoid или tanh влияет на скрытый слой? Почему для данной цели используется линейный выход?
8. Сколько обновлений весов выполнено за эпоху и за весь опыт? Как на расчёт повлиял `batch_size`?
9. Что измеряют MSE, MAE и RMSE и в каких единицах вы приведёте каждую величину?
10. Почему значения потерь MSE и MAE нельзя сравнивать напрямую? Какие общие метрики вы использовали?
11. Как ширина, глубина, число эпох, пакет и оптимизатор повлияли на результаты? Какие наблюдения поддерживают выводы?
12. Какие участки кривых дают основания подозревать переобучение? Что изменил бы ранний останов и как выбираются возвращаемые веса?
13. Почему выбор по одной валидации ограничивает вывод о качестве на будущих домах?
14. Какие свойства таблицы `Id, SalePrice` можно проверить без известных цен и какие сведения нужны для оценки ошибки?

Практическая работа № 3. Свёрточные нейронные сети

3.1. Постановка задачи

Требуется классифицировать изображения пяти видов цветов: ромашки, одуванчики, розы, подсолнухи и тюльпаны. Используется набор Flowers Recognition с каталогами `daisy`, `dandelion`, `rose`, `sunflower`, `tulip`.

Сравнение включает три модели:

1. заданная свёрточная сеть, обучаемая с нуля;
2. предобученная свёрточная архитектура с новой головой классификации;
3. собственная архитектура студента, обучаемая с нуля.

Общее разбиение позволяет сопоставить качество на одних и тех же фотографиях. Реализация дана на PyTorch. Для TensorFlow/Keras потребуется перенести слои, режимы, предобработку и протокол целиком.

3.2. Изображение как тензор

Тензор — многомерный массив чисел. Цветное изображение содержит три канала RGB: красный, зелёный и синий. В PyTorch пакет изображений имеет форму (B, C, H, W): размер пакета, число каналов, высота, ширина. Для принятого входа это $(B, 3, 224, 224)$. `ImageFolder` читает метки из имён каталогов и формирует `class_to_idx`. Это отображение связывает числовые ответы сети с названиями цветов [24].

Преобразование в тензор переводит обычные 8-битные RGB-пиксели в значения от 0 до 1. Затем выполняется нормализация каналов:

$$z_{c,h,w} = \frac{x_{c,h,w} - \mu_c}{\sigma_c}, \qquad x_{c,h,w} = \sigma_c z_{c,h,w} + \mu_c. \tag{3.1}$$

Здесь используются $\mu = (0{,}485, 0{,}456, 0{,}406)$ и $\sigma = (0{,}229, 0{,}224, 0{,}225)$ — фиксированные константы нормализации ImageNet. Статистики по набору цветов для этой операции не вычисляются. Индекс c обозначает канал, h, w — положение пикселя. При визуализации обратная формула восстанавливает цвет; прямой `clip(0,1)` нормализованного тензора его искажает.

Все три модели получают `Resize((224,224))`, преобразование в тензор и одну нормализацию. Такое изменение размера может менять пропорции изображения. Рекомендованная предобработка весов ResNet18, `weights.transforms()`, включает изменение размера и центральную обрезку [25]. Её влияние можно проверить отдельным опытом, применив выбранные преобразования ко всем сравниваемым моделям.

Аугментация создаёт изменённые варианты обучающих изображений, например зеркальные отражения. Модель встречает больше допустимых вариантов объекта, поэтому преобразование должно сохранять его класс. В основном сравнении случайные преобразования выключены; их влияние можно исследовать отдельно. На валидации преобразования фиксированы.

3.3. Свёрточный слой

Полносвязный слой рассматривает все входные координаты совместно. Свёрточный слой использует небольшой локальный участок и одни и те же веса в разных пространственных положениях. Для шага 1 и без дополнения границы один выходной канал вычисляется по правилу

$$a_{o,h,w} = b_o + \sum_{c=1}^{C_{in}} \sum_{u=0}^{k_h-1} \sum_{v=0}^{k_w-1} W_{o,c,u,v}\, x_{c,h+u,w+v}. \tag{3.2}$$

Здесь o — выходной канал, c — входной; u, v перебирают элементы ядра размера $k_h \times k_w$. Веса W и смещение b_o обучаются. В `Conv2d` реализуется взаимная корреляция: ядро в этой записи не переворачивается. В нейронных сетях операцию традиционно называют свёрткой [26]. Полученные карты признаков — таблицы откликов фильтров в разных участках изображения — проходят через нелинейность, например ReLU. Обучение определяет, какие локальные сочетания полезны для классификации.

> **Маленький расчёт**
>
> Для одной карты $X = \left[\begin{smallmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{smallmatrix}\right]$, ядра $K = \left[\begin{smallmatrix} 1 & 0 \\ 0 & 2 \end{smallmatrix}\right]$, нулевого смещения и шага 1 без padding получается $\left[\begin{smallmatrix} 11 & 14 \\ 20 & 23 \end{smallmatrix}\right]$. Например, левый верхний элемент равен $1 + 2 \cdot 5 = 11$. Найдите остальные элементы вручную.

Шаг задаёт расстояние между соседними положениями ядра. Padding дополняет границу входа, а dilation задаёт расстояние между соседними элементами ядра при его наложении. Для размера входа H, ядра k, шага s, padding p и dilation d высота выхода равна

$$H_{out} = \left\lfloor \frac{H + 2p - d(k-1) - 1}{s} + 1 \right\rfloor. \tag{3.3}$$

Для ширины действует такая же формула. В этой работе $d = 1$. При $k = 3$, $s = 1$, $p = 1$ размер сохраняется. Пусть C_{in} и C_{out} — число входных и выходных каналов. Для обычной свёртки без групп со смещением число параметров

$$P = C_{out}(C_{in} k_h k_w + 1). \tag{3.4}$$

Первый слой $3 \to 32$ с ядром 3×3 содержит $32(3 \cdot 3 \cdot 3 + 1) = 896$ параметров. Эти веса используются во всех положениях ядра, поэтому их число не растёт с площадью изображения.

3.4. Pooling и устройство исходной сети

`MaxPool2d(2,2)` выбирает максимум в каждом окне 2×2 и уменьшает высоту и ширину вдвое для чётного входа. Он не обучает веса. Pooling уменьшает пространственную детализацию и стоимость следующих вычислений; это не означает полной устойчивости классификатора к любому сдвигу или повороту.

Таблица 7: Размерности исходной CNN при входе 224×224

Последовательность операций	Форма без размера пакета
Вход RGB	$3 \times 224 \times 224$
Conv $3 \to 32$, ReLU, Conv $32 \to 64$, ReLU, MaxPool	$64 \times 112 \times 112$
Conv $64 \to 128$, ReLU, Conv $128 \to 128$, ReLU, MaxPool	$128 \times 56 \times 56$
Conv $128 \to 256$, ReLU, Conv $256 \to 256$, ReLU, MaxPool	$256 \times 28 \times 28$
Flatten	200704
Linear, ReLU; Linear, ReLU; Linear	$1024 \to 512 \to 5$

Все свёртки в таблице имеют ядро 3, шаг 1 и padding 1. Эта архитектура реализована функцией `original_cnn()`. Flatten располагает значения карт в одном векторе, сохраняя их число.

> **Почему нужно заранее оценить память**
>
> Слой $200704 \to 1024$ содержит 205 521 920 параметров со смещением. Вся исходная сеть — 207 175 365. Только веса float32 занимают около 0,77 GiB. Веса, градиенты и два состояния Adam суммарно требуют около 3,09 GiB, ещё без активаций и временных буферов. Это расчёт по архитектуре, а не измерение пикового расхода памяти.

Слой `AdaptiveAvgPool2d(1)` усредняет каждую карту, превращая $C \times H \times W$ в $C \times 1 \times 1$. Голова классификации получает один средний отклик на канал и предсказывает пять классов. Сокращение её входа уменьшает число параметров; влияние на качество проверяется экспериментом.

3.5. Логиты, cross-entropy и обучение

Последний слой выдаёт пять логитов $z_1, \ldots, z_5$ — оценок классов, которые могут быть любыми вещественными числами. Softmax превращает их в вероятности с суммой 1. Для объекта i с правильным классом y_i потеря зависит от вероятности этого класса:

$$p_c = \frac{e^{z_c}}{\sum_{j=1}^{5} e^{z_j}}, \qquad L = -\frac{1}{B} \sum_{i=1}^{B} \log p_{i,y_i}. \tag{3.5}$$

`CrossEntropyLoss` принимает исходные логиты формы $(B, 5)$ и целочисленные индексы классов формы $(B,)$ с типом `torch.long`. Она включает нужное преобразование логитов, поэтому отдельный Softmax перед ней не нужен [27]. Для выбора класса достаточно `logits.argmax(dim=1)`: наибольший логит и наибольшая вероятность имеют один индекс. Значение softmax само по себе не подтверждает надёжность прогноза.

Итерация обучения включает обнуление градиентов, прямой проход, вычисление потери, обратный проход и шаг оптимизатора. При проверке выполняются прямой проход и расчёт метрик. Вызов `model.eval()` переключает поведение слоёв, а `torch.no_grad()` отключает построение графа для расчёта градиентов. Для проверки нужны обе операции.

Метрики считают заново для каждой эпохи и отдельно для обучения и валидации. В средней потере каждый пакет учитывается по числу изображений n_b:

$$L_{epoch} = \frac{\sum_b n_b L_b}{\sum_b n_b}. \tag{3.6}$$

Например, для пакетов из 32 и 8 изображений нельзя брать простое среднее двух потерь. Accuracy считают по всем правильным ответам фазы, macro-F1 — по всем её меткам и прогнозам, а не как невзвешенное среднее F1 пакетов.

3.6. Перенос обучения и заморозка

Предобученная сеть уже получила веса на другой задаче. Основную часть сети, преобразующую изображение в признаки, называют **извлекателем признаков (backbone)**. Завершающий блок переводит признаки в ответы нашей задачи; это **голова классификации (head)**. В этой работе используется перенос с фиксированным извлекателем и обучением новой головы. При **дообучении (fine-tuning)** дополнительно изменяют часть предобученных слоёв [28].

В 2019 году команда Pinterest описала обучаемые векторные представления изображений, применявшиеся в визуальном поиске и рекомендациях [35]. Такое представление можно использовать в разных задачах; в нашей работе голова классификации переводит признаки изображения в пять логитов, по которым выбирается класс.

Пример использует ResNet18 с явно указанными весами `IMAGENET1K_V1`. Основой сети служат остаточные блоки: к преобразованию входа добавляется путь, передающий сам вход. Если размеры совпадают, блок имеет вид $h_{next} = \mathrm{ReLU}(F(h) + h)$; при изменении размеров применяется согласующее преобразование короткого пути. Четыре группы блоков используют 64, 128, 256 и 512 каналов; после глобального усреднения заменяется слой `fc` на $512 \to 5$ [29, 25].

`requires_grad=False` исключает параметры из расчёта их градиентов. Новая голова создаётся после заморозки и остаётся обучаемой; её параметры включаются в оптимизатор. В режиме `train` BatchNorm нормализует промежуточные значения по статистикам пакета и обновляет накопленные оценки средних и дисперсий в служебных значениях — буферах. В режиме `eval` он использует сохранённые оценки. Буферы меняются при обучении даже с замороженными параметрами [30]. Поэтому для полностью фиксированного извлекателя backbone работает в `eval`, а новая голова — в `train`. Общий вызов `model.train()` переключил бы и backbone в режим обучения.

Веса ResNet получены на внешних данных. При сравнении с обучением с нуля это дополнительный ресурс: результат характеризует архитектуру вместе с выбранным способом получения весов.

3.7. Подготовка изображений и разбиение

Шаг 1. Изучите набор и проверьте ресурсы

Выведите классы, число изображений каждого класса и несколько исходных примеров. Откройте одно изображение и сопоставьте его с меткой. Проверьте читаемость файлов, размеры, цветовые каналы и дубликаты: состав набора зависит от версии выгрузки. Выберите устройство и запишите его в отчёте.

```
import torch
from lab3_utils import prepare_flowers, seed_everything
from lab3_utils import original_cnn, transfer_resnet18, compact_example
from lab3_utils import fit_flowers, plot_learning, parameter_counts
seed_everything(0)
device = "cuda" if torch.cuda.is_available() else "cpu"
print(device)
```

Шаг 2. Зафиксируйте одну валидацию

Целевой размер валидации — 1000 изображений. Точные копии файлов объединяются по SHA-256 и целиком попадают в одну часть, поэтому фактический размер может отличаться от 1000. `split.csv` сохраняет итоговое распределение. Выведите пропорции классов и проверьте наличие всех пяти классов в обеих частях: групповое разделение само по себе этого не гарантирует.

```
data = prepare_flowers("data", validation_target=1000,
                       seed=0, image_size=224, augment=False)
print(data["class_to_idx"])
print(data["inventory"].groupby(["split", "target"]).size())
print(data["config"])
```

Хеши находят побайтовые копии. После повторного сжатия, обрезки или изменения размера снимки одной сцены могут иметь разные хеши. Если такие серии известны, объедините их до разделения. Совпадающие файлы с разными метками требуют проверки разметки; причину исправления укажите в отчёте.

Функция создаёт отдельные объекты `ImageFolder` для обучения и валидации с одним списком файлов и разными подмножествами. Это позволяет в дополнительном опыте применять случайное отражение только к обучению. Если два `Subset` используют общий объект, замена его `transform` изменит обе части одновременно.

> **Контрольная точка 1**
>
> Пакет имеет форму $(B, 3, 224, 224)$, метки — целочисленный вектор длины B со значениями от 0 до 4. Известно отображение индексов в имена. Обучение и валидация не пересекаются по файлам и точным дубликатам. Все три архитектуры используют одно сохранённое разбиение.

3.8. Обучение и исследование архитектур

Шаг 3. Разберите и обучите заданную CNN

Выпишите размеры тензоров после свёрток и pooling, проверьте вход первого Linear и число параметров. Оцените память по расчёту из теоретического раздела. Создайте новую модель, затем оптимизатор. Изучите `fit_flowers` в `lab3_utils.py`: найдите сброс метрик, переключение режима и выбор сохранённых весов. Параметры основного запуска заданы явно:

```
seed_everything(0)
model = original_cnn()
print(parameter_counts(model))
result_original = fit_flowers(
    model, data, "runs/lab3_original_01", epochs=10,
    batch_size=32, learning_rate=1e-3, seed=0, device=device
)
```

Перед полным запуском выполните прямой и обратный проход на одном пакете, проверьте форму выхода. Такой запуск проверяет совместимость размеров и достаточность памяти. Если памяти недостаточно, уменьшите пакет и зафиксируйте общий протокол для всех трёх моделей. Уменьшение разрешения у исходной сети потребует изменения первого Linear; изменённую архитектуру укажите отдельно. Ошибку памяти зафиксируйте как неудавшийся запуск без метрики качества.

Шаг 4. Примените перенос обучения

Выберите предобученную архитектуру, прочитайте её описание и определите слой классификатора. Для ResNet18 заморозьте старые параметры, затем создайте новую голову. В таком порядке её параметры сохраняют разрешение на вычисление градиентов:

```
from torchvision import models
from torch import nn
weights = models.ResNet18_Weights.IMAGENET1K_V1
model = models.resnet18(weights=weights)
for p in model.parameters():
    p.requires_grad = False
model.fc = nn.Linear(model.fc.in_features, 5)
model.frozen_backbone = True
for name, p in model.named_parameters():
    if p.requires_grad:
        print(name, p.shape)
```

Вывод должен содержать только `fc.weight` и `fc.bias`. Для головы $512 \to 5$ обучается $512 \cdot 5 + 5 = 2565$ параметров. При первом использовании веса могут загружаться из сети. Значение `weights=None` создаёт случайную инициализацию; для переноса нужны предобученные веса.

Функция `transfer_resnet18()` выполняет эту настройку и сохраняет обозначение весов в метаданных. Обучите новую модель в отдельном каталоге:

```
seed_everything(0)
model = transfer_resnet18(pretrained=True)
result_transfer = fit_flowers(
    model, data, "runs/lab3_transfer_01", epochs=10,
    batch_size=32, learning_rate=1e-3, seed=0, device=device
)
```

Проверьте, что после шага обучения параметры backbone и накопленные статистики BatchNorm сохранились. Для дополнительного опыта с fine-tuning укажите размороженные слои, режим BatchNorm и новый оптимизатор: эти настройки определяют, какая часть сети меняется.

Шаг 5. Создайте собственную архитектуру

Выберите проверяемую гипотезу и предложите соответствующее изменение: размер головы, ширину или глубину блоков, регуляризацию, способ агрегирования карт. Нарисуйте последовательность слоёв, рассчитайте формы и число параметров. Выход должен содержать пять логитов. Пример использует глобальное усреднение:

```
student_model = nn.Sequential(
    nn.Conv2d(3, 16, 3, padding=1), nn.ReLU(), nn.MaxPool2d(2),
    nn.Conv2d(16, 32, 3, padding=1), nn.ReLU(), nn.MaxPool2d(2),
    nn.Conv2d(32, 64, 3, padding=1), nn.ReLU(),
    nn.AdaptiveAvgPool2d(1), nn.Flatten(), nn.Linear(64, 5)
)
```

Внесите как минимум одно обоснованное структурное изменение относительно примера `compact_example()` и объясните ожидаемый эффект. Зафиксируйте seed *до* создания слоёв, чтобы он определял начальные веса. Обучите свой вариант с тем же разбиением и основным бюджетом.

3.9. Сравнение, визуализация и сохранение

Шаг 6. Соберите сопоставимые результаты

Основной протокол: RGB 224×224, фиксированная нормализация, без случайной аугментации, seed 0, Adam с шагом 10^{-3}, пакет 32, десять эпох. Для каждой модели создаются новые загрузчики с тем же начальным seed. Выбирается эпоха с наибольшим macro-F1 валидации; при равенстве сохраняется более ранняя. Укажите предобучение ResNet18 как дополнительный ресурс.

Таблица 8: Что должно быть в итоговой таблице CNN

Группа полей	Содержание
Модель	Имя, схема, число всех и обучаемых параметров; исходные веса
Обучение	Разбиение, seed, эпохи, пакет, оптимизатор, шаг, размер входа, аугментация
Результат	Лучшая эпоха, loss, accuracy и macro-F1 одной валидации
Ресурсы	Устройство, измеренное время с указанием границ измерения; при измерении — пиковая память
Вывод	Какие классы и случаи улучшились или ухудшились; ограничения сравнения

В `fit_flowers` время охватывает обучение, валидацию и запись контрольных точек. Первоначальная загрузка предобученных весов и подготовка набора выполняются вне этого измерения. Сопоставляйте время за одинаковые этапы; одинаковое число эпох у разных сетей может требовать разного числа операций.

Шаг 7. Постройте графики и исследуйте прогнозы

Для каждой модели покажите train/validation loss и macro-F1 по эпохам, а затем общую диаграмму результатов трёх архитектур. Сохраните матрицы ошибок и classification report по пяти классам. Используйте одинаковые оси и порядок меток, подпишите доли или проценты.

```
fig = plot_learning(result_transfer)
fig.savefig("runs/lab3_transfer_01/curves.pdf", bbox_inches="tight")
```

Покажите девять заранее выбранных изображений валидации либо все, если их меньше. Для каждого укажите истинный и предсказанный класс, восстановите цвета. Дополнительно разберите несколько ошибок. Для прогноза одного нормализованного изображения выполните:

```
from lab3_utils import denormalize
import matplotlib.pyplot as plt
index = int(data["validation_indices"][0])
image, label = data["validation_dataset"][index]
model = result_transfer["model"]
model.eval()
with torch.no_grad():
    logits = model(image.unsqueeze(0).to(device))
predicted = int(logits.argmax(1).item())
plt.imshow(denormalize(image).permute(1, 2, 0))
plt.title(f"True: {data['classes'][label]}; predicted: {data['classes'][predicted]}")
plt.axis("off")
```

Шаг 8. Сохраните воспроизводимый комплект

Каждая архитектура получает свой каталог. Основные файлы:

- `split.csv` — список изображений и разбиение;
- `history.csv` — история обучения по эпохам;
- `best_weights.pth` — выбранные веса;
- `manifest.json` — параметры и результаты опыта;
- `architecture.txt` — текстовое описание модели.

Также сохраняются прогнозы, отчёт и матрица ошибок. Приложите исходный код собственной архитектуры. Для восстановления вместе с весами нужны совместимое определение модели, те же преобразования и тот же словарь классов.

3.10. Контрольные вопросы

1. Чем CNN отличается от полносвязной сети по связям, параметрам и работе с пространством?
2. Что задают kernel size, stride, padding, входные и выходные каналы? Рассчитайте размер выхода одного слоя.
3. Как работают свёртка и pooling в исходной сети? Какие из них имеют обучаемые параметры?
4. Почему первый Linear исходной архитектуры требует так много памяти?
5. Что такое логиты? Почему перед CrossEntropyLoss не добавляется Softmax?
6. Зачем нужны одновременно eval и отключение градиентов?
7. Что такое предобучение, transfer learning и fine-tuning? Откуда взяты веса выбранной модели?
8. Как устроена выбранная предобученная архитектура? Для ResNet объясните короткий путь и сложение в блоке.
9. Что делает requires_grad? Почему заморозка параметров не равна заморозке статистик BatchNorm?
10. Какое изменение вы внесли в собственную сеть и какую гипотезу проверяли?
11. Почему нельзя накапливать счётчики разных эпох или усреднять F1 пакетов как F1 всего набора?
12. Как корректно показать нормализованное изображение? Почему clip без обратной нормализации неверен?
13. Что можно и чего нельзя заключить из сравнения с предобученной сетью?

Общие требования к отчёту

Структура отчёта

Используйте шаблон приложения 3.10. В основном тексте оставьте постановку задачи, условия сравнения, результаты и разбор ошибок. Ноутбук, полные таблицы прогнозов и файлы модели приложите отдельно. Названия опытов в отчёте должны совпадать с именами сохранённых запусков.

Критерии оценивания

Критерий	Наблюдаемый признак выполнения
Данные	Известны признаки и цель; нет утечки, перепутанных выборок и неверных меток.
Модель	Студент объясняет алгоритм, размерности, потери и изменяемые настройки.
Эксперимент	Сравнения воспроизводимы; сохранены разбиения, seed, версии и результаты.
Анализ	Показаны ошибки и ограничения; выводы следуют из полученных результатов.
Самостоятельность	Есть обоснованный выбор, исследование параметров и собственная архитектура в работе № 3.

Баллы, минимальные пороги и правила пересдачи задаёт рабочая программа дисциплины. Качество прогноза оценивают вместе с корректностью эксперимента: утечка данных может повысить метрику, но делает вывод ненадёжным. Неудачный вариант модели также включите в сравнение и объясните по результатам диагностики.

Обсуждение результатов на защите

Подготовьтесь объяснить путь одного объекта от исходных признаков до прогноза, выбранную метрику и условия сравнения моделей. Для изменения гиперпараметра сопоставьте ожидаемый эффект с полученным. Расхождение между ними может указывать на переобучение, ограничения данных или ошибку реализации; различить эти причины помогают графики и отдельные прогнозы.

Современные модели для таблиц: дополнительное чтение

Во второй работе полносвязная сеть обучалась на признаках домов. TabM развивает идею объединения нескольких прогнозов, а TabPFN-3 использует предварительное обучение на таблицах. Этот раздел и опыт с усреднением дополнительны.

TabM: несколько прогнозов внутри одной модели

Ансамбль объединяет ответы нескольких моделей. Пусть три сети оценили цену одного дома в 180, 190 и 200 условных единиц. Их среднее равно 190. Когда ошибки имеют разные знаки, усреднение может их частично компенсировать. Если все сети систематически завышают цену, средний прогноз тоже окажется завышенным.

Ансамбль отдельных нейросетей требует обучить и хранить каждую из них. В **TabM**, представленном на ICLR 2025, несколько вариантов MLP обучаются вместе и используют общую большую часть параметров. Для одного объекта модель объединяет прогнозы вариантов [32].

TabPFN-3: использовать опыт предварительного обучения

В **TabPFN-3** предварительное обучение выполняется на искусственно созданных таблицах. Для новой задачи модель получает примеры с известными ответами и признаки объектов, для которых ответ нужно предсказать. Например, известные цены домов и их характеристики служат контекстом для оценки других домов. Такой способ называют *in-context learning* — обучением на примерах в контексте [33].

Затратное предварительное обучение создаёт готовые веса. При применении к новой таблице информация об известных ответах передаётся через контекст; для такого прогноза не обязательно заново настраивать веса градиентными шагами.

Источник по TabPFN-3 — **технический отчёт мая 2026 года**. Авторы сообщают результаты своих экспериментов [33]. Качество на файлах курса потребовало бы отдельной проверки.

Условия сравнения

Для сравнения нужны общее разбиение, одна шкала ошибки и учёт времени и памяти. У предобученной модели затраты распределены между предварительным обучением и применением к новой таблице, поэтому границы измерения следует указать явно.

Подход	Получение прогноза для новой таблицы
MLP из работы № 2	Настроить веса одной сети на обучающей части; передать ей признаки нового дома.
TabM	Совместно обучить варианты с общими параметрами на обучающей части; объединить их ответы.
TabPFN-3	Передать готовой модели обучающие примеры с ответами и признаки новых объектов.

Необязательное задание: помогает ли усреднение?

Средствами работы № 2 можно проверить усреднение прогнозов трёх отдельных сетей. TabM и TabPFN-3 для этого опыта не требуются.

1. Сохраните одно разбиение домов и одну предобработку из работы № 2. Выберите исходную конфигурацию B0.
2. Обучите три новые копии этой сети с seed 40, 41 и 42. Seed обучения влияет на начальные веса и случайный порядок объектов. Разбиение данных и остальные настройки оставьте теми же.
3. Для каждой сети сохраните прогнозы валидации в исходных единицах цены. В учебном модуле это поле `validation_predictions` результата `run_experiment`.
4. Для каждого дома усредните три прогноза:

$$\widehat{y}_i^{\,avg} = \frac{\widehat{y}_i^{(1)} + \widehat{y}_i^{(2)} + \widehat{y}_i^{(3)}}{3}.$$

   Перед расчётом метрик проверьте, что в трёх массивах прогнозов сохранён один порядок домов.
5. Составьте четыре строки результата: три отдельные сети и усреднение. Для каждой укажите MAE и RMSE на одной валидации. Сравните также затраты на три обучения и на одно.

Покажите один дом, для которого усреднение помогло, и один, для которого не помогло, если такие примеры есть. Объясните наблюдение по знакам и величинам ошибок отдельных сетей. Вывод относится к выбранному разбиению. Разброс трёх прогнозов сам по себе не задаёт гарантированного интервала цены.

Форма сдачи: таблица, два разобранных примера и вывод на полстраницы.

Список литературы

[1] Reyes-Ortiz J., Anguita D., Ghio A., Oneto L., Parra X. Human Activity Recognition Using Smartphones. UCI Machine Learning Repository, 2013. https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones.

[2] scikit-learn. GroupShuffleSplit. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html.

[3] scikit-learn. Common pitfalls and recommended practices. https://scikit-learn.org/stable/common_pitfalls.html.

[4] scikit-learn. StandardScaler. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html.

[5] scikit-learn. KNeighborsClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html.

[6] scikit-learn. LinearSVC. https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html.

[7] scikit-learn. RandomForestClassifier. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html.

[8] scikit-learn. classification_report. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html.

[9] scikit-learn. SimpleImputer. https://scikit-learn.org/stable/modules/generated/sklearn.impute.SimpleImputer.html.

[10] scikit-learn. OneHotEncoder. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html.

[11] Keras. The Sequential model. https://keras.io/guides/sequential_model/.

[12] Keras. Dense layer. https://keras.io/api/layers/core_layers/dense/.

[13] Keras. Layer activation functions. https://keras.io/api/layers/activations/.

[14] Keras. Regression losses. https://keras.io/api/losses/regression_losses/.

[15] scikit-learn. Metrics and scoring: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html.

[16] Keras. Model training APIs. https://keras.io/api/models/model_training_apis/.

[17] Keras. SGD. https://keras.io/api/optimizers/sgd/.

[18] Keras. Adam. https://keras.io/api/optimizers/adam/.

[19] Keras. EarlyStopping. https://keras.io/api/callbacks/early_stopping/.

[20] Keras. Python & NumPy utilities. https://keras.io/api/utils/python_utils/.

[21] TensorFlow. enable_op_determinism. https://www.tensorflow.org/api_docs/python/tf/config/experimental/enable_op_determinism.

[22] scikit-learn. ColumnTransformer. https://scikit-learn.org/stable/modules/generated/sklearn.compose.ColumnTransformer.html.

[23] PyTorch. Optimizing Model Parameters. https://docs.pytorch.org/tutorials/beginner/basics/optimization_tutorial.html.

[24] Torchvision. ImageFolder. https://docs.pytorch.org/vision/stable/generated/torchvision.datasets.ImageFolder.html.

[25] Torchvision. ResNet18 and pretrained weights. https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html.

[26] PyTorch. Conv2d. https://docs.pytorch.org/docs/stable/generated/torch.nn.Conv2d.html.

[27] PyTorch. CrossEntropyLoss. https://docs.pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html.

[28] PyTorch. Transfer Learning for Computer Vision Tutorial. https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html.

[29] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016. https://arxiv.org/abs/1512.03385.

[30] PyTorch. BatchNorm2d. https://docs.pytorch.org/docs/stable/generated/torch.nn.BatchNorm2d.html.

[31] Mamaev A. Flowers Recognition. Набор изображений из исходного задания. https://www.kaggle.com/datasets/alxmamaev/flowers-recognition.

[32] Gorishniy Y., Kotelnikov A., Babenko A. TabM: Advancing Tabular Deep Learning with Parameter-Efficient Ensembling. ICLR, 2025. https://arxiv.org/abs/2410.24210.

[33] Grinsztajn L., Flöge K., Key O. et al. TabPFN-3: Technical Report. Технический отчёт, май 2026, версия 2. https://arxiv.org/abs/2605.13986v2.

[34] Del Balso M., Hermann J. Meet Michelangelo: Uber's Machine Learning Platform. Uber Engineering, 5 September 2017. https://www.uber.com/us/en/blog/michelangelo-machine-learning-platform/.

[35] Zhai A., Wu H.-Y., Tzeng E., Park D. H., Rosenberg C. Learning a Unified Embedding for Visual Search at Pinterest. KDD, 2019. https://arxiv.org/abs/1908.01707.

[36] Babushkin V., Kravchenko A. Machine Learning System Design: With End-to-End Examples. Manning, 2025. https://www.manning.com/books/machine-learning-system-design.

[37] Николенко С. И., Кадурин А. А., Архангельская Е. О. Глубокое обучение. — СПб.: Питер, 2026. — 480 с. https://www.piter.com/collection/A31900/product/glubokoe-obuchenie-2.

Дата обращения к документации и наборам данных: 15.09.2026; к статьям TabM и TabPFN-3: 16.09.2026; к описаниям рабочих систем и страницам издательств: 10.10.2026. API библиотек сверялся с официальной документацией; при использовании другой версии проверьте сигнатуры вызываемых функций.

Приложение А. Материалы эксперимента

Каждому запуску назначьте отдельную папку. Ниже приведён пример для работы № 2:

```
runs/B0_01/
    manifest.json
    history.csv
    validation_predictions.csv
    predictions_raw.csv
    model.keras
    preprocessing.joblib
    diagnostics.pdf
```

`manifest.json` описывает условия запуска: конфигурацию, разбиение, версии библиотек, контрольные суммы данных, подготовленные признаки и метрики валидации. По `history.csv` можно восстановить ход обучения, а `validation_predictions.csv` содержит пары истинных и предсказанных цен для разбора ошибок. Сохранённая модель применяется вместе с её `preprocessing.joblib`: этот файл определяет заполнение пропусков, кодирование категорий и масштабирование входа и цели.

Графики добавляются после сохранения опыта:

```
fig.savefig("runs/B0_01/diagnostics.pdf", bbox_inches="tight")
```

Для названий файлов придерживайтесь одного идентификатора опыта: в приведённой строке папка `runs/B0_01` должна совпасть с аргументом вашего вызова `save_experiment`. Не открывайте файлы сериализованной предобработки из неизвестных источников; этот комплект предназначен для сохранённых вами опытов.

Пример вывода по сравнению моделей

Условный пример: при увеличении ширины скрытого слоя с 64 до 128 нейронов RMSE на обучении снизилась с 25 до 20 тысяч денежных единиц, а на валидации выросла с 30 до 33 тысяч. Разбиение и остальные настройки оставались фиксированными. Такая картина согласуется с переобучением: более широкая сеть лучше описывает обучающие объекты, но её прогноз для новых объектов ухудшается. Один запуск ещё не показывает устойчивость эффекта; для этого нужно повторить сравнение с другими начальными весами.

В собственном выводе разделяйте наблюдение, его возможное объяснение и ограничение эксперимента. Числа этого примера не являются результатами на наборе курса.

Что сохраняется в других работах

В работе № 1 сохраняются таблица сравнения валидации, тестовые прогнозы, classification report, обученный Pipeline и описание группового разбиения. В работе № 3 — список изображений с метками и разбиением, история каждой эпохи, выбранные веса, описание архитектуры, словарь классов, метрики и прогнозы.

Для повторения собственной CNN сохраните её исходный код, преобразование входного изображения и словарь классов вместе с весами.

Словарь основных обозначений

Символ	Значение
$x_i, y_i, \widehat{y}_i$	Признаки, истинный ответ и прогноз для объекта i.
d, n	Число признаков и число объектов в текущем наборе.
θ	Обучаемые параметры модели.
B	Размер мини-выборки; фактический последний пакет может быть меньше.
η	Скорость обучения.
C_{in}, C_{out}	Число входных и выходных каналов свёртки.
H, W	Высота и ширина карты признаков.
TP, FP, FN	Верно найденные объекты класса, ложные срабатывания и пропуски.

В работе № 1 параметр C без индекса обозначает гиперпараметр LinearSVC; в матрице C_{ij} индексы обозначают пару истинного и предсказанного классов. Смысл определяется контекстом, а не одним символом.

Приложение Б. Шаблон отчёта

Требования к оформлению титульного листа, объёму и сроку сдачи сообщает преподаватель.

Сведения о работе

Дисциплина: _____

Лабораторная работа № ____. Название: _____

Выполнил(а): _____ Группа: _____

ИТМО ID: _____ Проверил(а): _____

Дата: _____ Версия материалов: _____

1. Цель и данные

Сформулируйте цель своими словами. Укажите источник и версию файлов, объект наблюдения, признаки и целевой ответ. Приведите размер набора и проверки его состава. Объясните, какие данные доступны при применении модели.

2. Условия эксперимента

Опишите разбиение и способ исключения утечки. Укажите среду, seed, модель, основную метрику выбора и бюджет. Для каждого опыта сформулируйте ожидаемый эффект изменения параметра до запуска. Дополнительные опыты явно отделяйте от исходного плана.

3. Результаты и разбор ошибок

Для сравнения опытов используйте следующую структуру таблицы.

Опыт	Что изменено	Метрика на указанной части	Наблюдение
Исходный	Конфигурация модели	Значение и единицы	Что видно по результату
Сравнение	Один фактор либо явно заданная комбинация	Та же метрика и часть	Изменение относительно исходного

Сошлитесь на диагностические графики и разберите конкретные ошибки. Для неудачного запуска запишите причину остановки; метрика такого опыта остаётся неопределённой.

4. Выводы и приложение к отчёту

Сформулируйте подтверждённый результат и ограничения вывода. Укажите пути к ноутбуку и сохранённым материалам опытов; состав файлов описан в приложении А.